


Проектирование Распределенных Систем


Двадцать первый семинар:
Leaderless-репликация.

Нестрогий кворум. Направленная передача



План семинара

- Повторение: репликация, согласованность, кворумы
- Проблема single и multi leader репликации
- Исторические Dynamo-style СУБД
- Идея leaderless репликации и координатора в ней
- Write-path по кворуму при отказе части узлов
- Компенсирующие согласованность действия (Repair):
 - Разрешение конфликтов при чтении
 - Антиэнтропия
- Нестрогий кворум (Sloppy Quorum) и направленная передача (Hinted Handoff)



Репликация. Повторение

Репликация. Повторение

Replication — хранение копий данных на нескольких узлах.

Репликация. Повторение

Replication — хранение копий данных на нескольких узлах.

Single-leader replication — один лидер принимает записи, реплики получают изменения от него.

Репликация. Повторение

Replication — хранение копий данных на нескольких узлах.

Single-leader replication — один лидер принимает записи, реплики получают изменения от него.

Multi-leader replication — несколько лидеров принимают записи
→ конфликты неизбежны.

Репликация. Повторение


Replication — хранение копий данных на нескольких узлах.

Single-leader replication — один лидер принимает записи, реплики получают изменения от него.

Multi-leader replication — несколько лидеров принимают записи
→ конфликты неизбежны.

Leaderless replication — нет фиксированного лидера, запись может принимать любой узел (координатор на время запроса)

Согласованность. Повторение



Кворум. Повторение

Кворум. Повторение

Кворум — это правила, согласно которым определяется минимальное число узлов, чьих подтверждений достаточно, чтобы операция считалась успешно выполненной в системе, где данные реплицированы на несколько узлов.

Кворум. Повторение

Кворум — это правила, согласно которым определяется минимальное число узлов, чьих подтверждений достаточно, чтобы операция считалась успешно выполненной в системе, где данные реплицированы на несколько узлов.

N (replication factor) — Количество реплик, на которых хранится один и тот же элемент данных (например, значение по ключу).

Кворум. Повторение

Кворум — это правила, согласно которым определяется минимальное число узлов, чьих подтверждений достаточно, чтобы операция считалась успешно выполненной в системе, где данные реплицированы на несколько узлов.

N (replication factor) — Количество реплик, на которых хранится один и тот же элемент данных (например, значение по ключу).

W (write quorum) — Минимальное число реплик из N, которые должны подтвердить запись, чтобы координатор вернул клиенту “запись успешна”.

Кворум. Повторение

Кворум — это правила, согласно которым определяется минимальное число узлов, чьих подтверждений достаточно, чтобы операция считалась успешно выполненной в системе, где данные реплицированы на несколько узлов.

N (replication factor) — Количество реплик, на которых хранится один и тот же элемент данных (например, значение по ключу).

W (write quorum) — Минимальное число реплик из N, которые должны подтвердить запись, чтобы координатор вернул клиенту “запись успешна”.


R (read quorum) — Число реплик из N, которые координатор опрашивает при чтении (и/или от которых ждет ответ), чтобы вернуть результат клиенту.

Кворум. Повторение


Кворум — это правила, согласно которым определяется минимальное число узлов, чьих подтверждений достаточно, чтобы операция считалась успешно выполненной в системе, где данные реплицированы на несколько узлов.

$$W + R > N$$


Проблема single и multi leader репликации




Проблема single и multi leader репликации



Но что если...



И даже если одна нога упадет...



Идеи о СУБД с leaderless репликацией



Dynamo-style DB




Dynamo-style DB





Идея Leaderless репликации

В отличии от single-leader




Идея Leaderless репликации

В отличии от single-leader




Идея Leaderless репликации

В Leaderless репликации каждая нода кластера способна принимать запросы как на чтение, так и на запись.



Идея Leaderless репликации

Чтение/запись в систему с leaderless репликацией должна происходить по какому-то набору правил — по **кворуму**




Идея Leaderless репликации

А раз лидера нет, то кто будет следить за соблюдением кворума?

Кто будет считать количества успешных ответов на запись от других нод?


Кто будет разрешать конфликты при чтении?




Идея Leaderless репликации. Вводим координатора

Координатор — нода, которая будет принимать конкретный запрос клиента, принимать решение о результате чтения, считать успешные результаты записи и отдавать клиенту финальный ответ.


Идея Leaderless репликации. Вводим координатора



Идея Leaderless репликации. Вводим координатора




Идея Leaderless репликации. Вводим координатора




Leaderless репликация.

Write-path при отказе части узлов




Leaderless репликация.

Write-path при отказе части узлов




Leaderless репликация.

Write-path при отказе части узлов




Компенсирующие согласованность действия

Repair-on-read



Компенсирующие согласованность действия

Repair-on-read



Компенсирующие согласованность действия

Anti-entropy-repair

1. Запуск процесса антиэнтропии
2. Выбор координатора антиэнтропии
3. Опрос других нод на предмет данных
4. Сверка данных между нодами
5. Устранение различия в данных (data repair)

